1、requests概述

前面的课程中我们了解了requests模块是一个网络请求模块，可以帮助我们模拟成客户端去请求服务器的数据。我们今天就是主要针对这个模块进行学习。

我们可以在浏览器中抓取到这些请求与响应的内容，那么我们可以“伪造”请求吗？也就是不再通过浏览器发送这些数据，而是通过Python来模拟浏览器发送请求。答案是可行的。而Requests模块就可以完成这种功能。

- Requests 模块就是 Python 实现的简单易用的 **HTTP库**

还有其他库吗? 回答也是肯定的，例如 urllib ， urllib2 等模块。但是目前来说 Requests 模块是最流行的。而且也是做好用的模块。利用pip 可以非常方便的安装：

```
pip install requests
```

2、requests模块请求参数

通过前面我们使用用requests模块已经知道，requests模块在发送网络请求的时候可以传递一些关键字参数，如下图我们写过的案例所示：

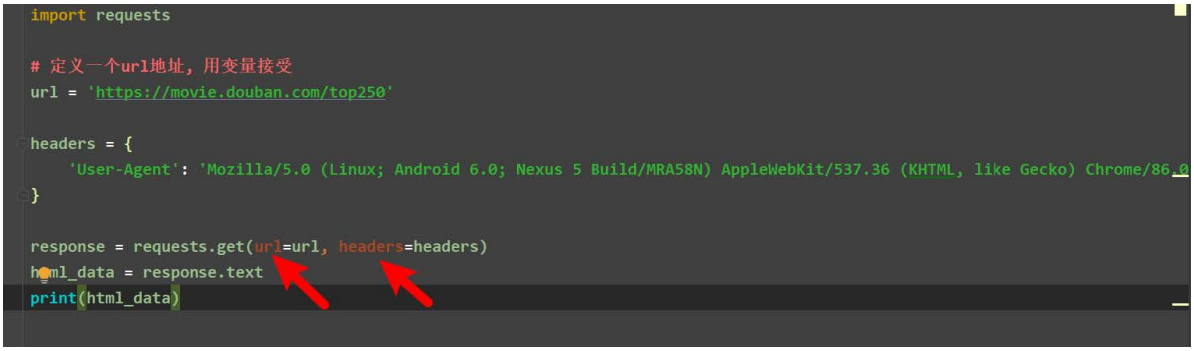

那么除了这两个关键字参数，requests模块在发送网络请求的时候还有哪些关键字参数呢？接下来我们通过查看源码的方式，介绍requests模块发送请求常用的关键字参数。如下所示：

```
"""
method: 请求方法 get post
url: 请求网址
params: (可选的) 查询参数

headers: (可选的) 字典 请求头
cookies: (可选的) 字典.cookiejar对象, 用户身份信息
proxies: (可选的) ip代理

data: (可选的) 字典.列表.元组.bytes post请求时会用到
json: (可选的) 字典 提交参数

verify: (可选的) 是否验证证书, ca证书
timeout: (可选的) 设置响应时间,一旦超过,程序会报错
allow_redirects: (可选的) 是否允许重定向, 布尔类型数据

files: (可选的) 字典,文件
```

```
auth: (可选的) 字典,权限认证
stream: (可选的) 是否是数据流传输
"""
```

以上关键字参数排列顺序根据使用的频率进行排列。

3、常见参数的使用

3、1 url地址中的参数

在使用requests模块发送请求之前，我们就要回顾之前学习到的url（统一资源定位符）。

在你拿到数据所在的url地址之后，发送网络请求时，请求的url中包含两种地址参数：**查询参数** 和 **请求参数。**

- **查询参数**

  当我们爬一些特殊网址时，请求的url中会有一些特殊的参数，例如以下站点：

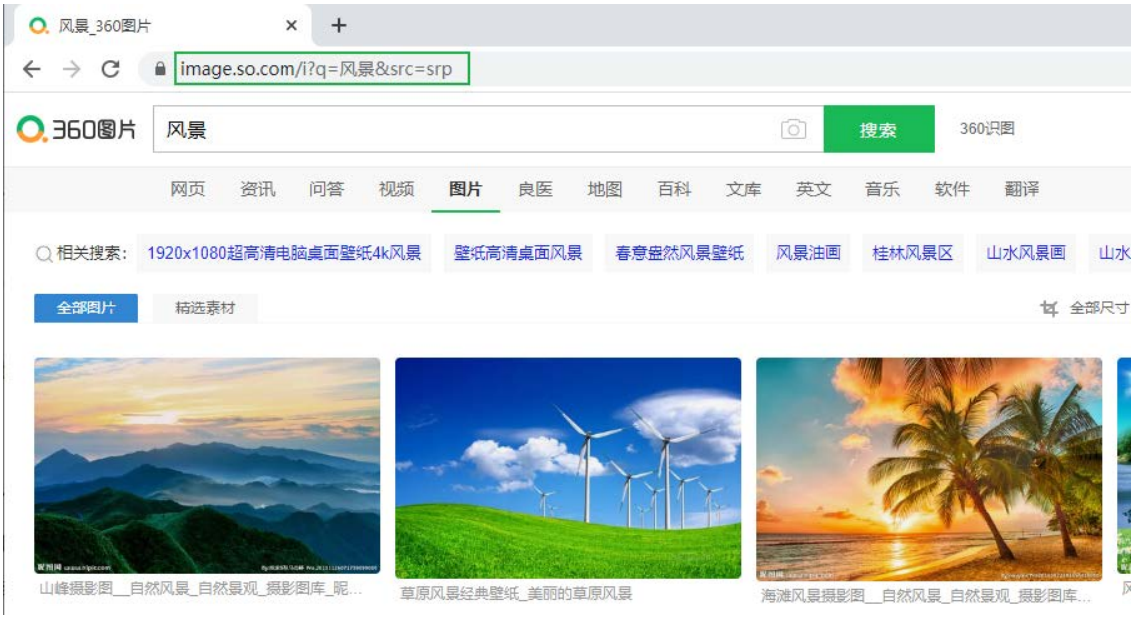

  这种是 **URL** 的查询参数。前面是网址，**？** 后面的二值性数据，就是查询参数。

  URL 的查询字符串(query string)传递某种数据。如果你是手工构建 URL，也就是通过拼接字符串构造的URL。那么数据会以键/值对的形式置于 URL 中，跟在一个问号的后面。

  例如：`https://image.so.com/i?q=%E9%A3%8E%E6%99%AF&src=srp`

  params关键字参数

  requests 模块允许你使用 **params** 关键字参数，以一个字典来提供这些参数。

  举例来说，如果你想传递 key1=value1 和 key2=value2 到 httpbin.org/get ，那么你可以使用如下代码：

```
import requests

params = {'q': '风景',  'src': 'srp'}
response = requests.get("https://image.so.com/i",  params=params)
```

  通过打印输出该 URL，你能看到 URL 已被正确编码：

```
print(response.url)
# 打印结果
https://image.so.com/i?q=%E9%A3%8E%E6%99%AF&src=srp
```

> **注意：**
>
> 在url地址中默认是不支持中文字符的，所以在请求中会把中文字符转化成url编码形式

同样的查询参数可以在浏览器抓包工具中找到，位于**Headers**栏目下的**Query String Parameters**中，如下图所示：

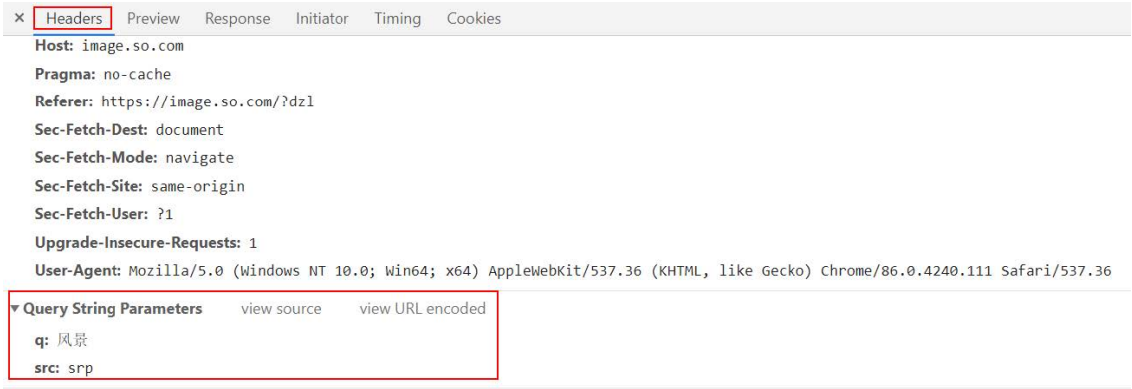

- **请求参数**

  请求参数和查询参数有本质的区别。请求参数一般是在发送**post**请求，向服务器提交表单数据请求的时候携带的参数。

> 注意：url地址中不会显示请求参数，只会显示查询参数。
>
> 请求参数在浏览器抓包工具中，位于Headers栏目下的Form Data中
>
> 如下面数据抓包所示：

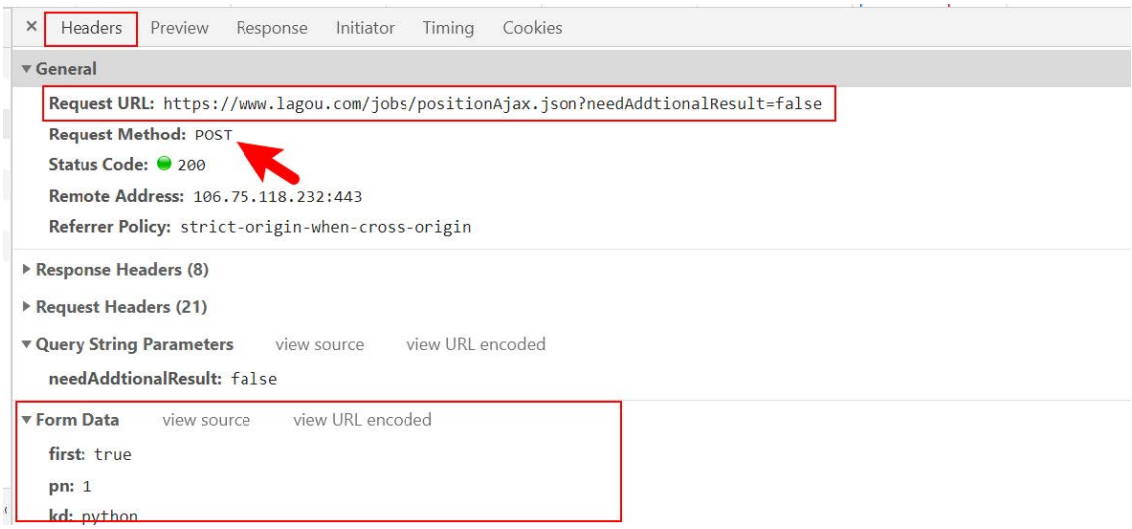

data关键字参数

在requests模块中发送POST请求也是比较容易的操作，要实现这个，只需简单地传递一个**字典**给**data**参数。你的数据字典在发出请求时会自动编码为表单形式：

```
data = {'key1': 'value1',  'key2': 'value2'}
response = requests.post("http://httpbin.org/post",  data=data)
```

当然Requests中的post方法只是相对于get方法多了一个data参数，其他参数都是类似的，例如我们也可以为post中的网址添加查询字符串 params 参数，也可以像get方法一样添加 headers 参数等。

3、2 cookies关键字参数

在前面我们学习http协议的时候，请求体字段中就讲述过cookies字段，这个字段代表用户身份的标识，一般平台通过这个字段存储用户信息，包括并不限于用户名、密码、登陆时间等等。一般cookies信息都是二值型的，即key=value形式，非常像字典的构造形式。每一个key=value的信息，都代表用户的片段信息，很多个key=value片段构成一个完整的cookies字段，如下图所示：

值得注意的是，cookies中所有片段信息，有浏览器自动生成的，也有服务器在响应数据的时候给你生成的。一旦服务给你生成了cookie片段，那么大概率就会针对这些片段进行校验，验证你的用户身份，从而决定是否返回数据给你。相反来说浏览器自动为我们生成的cookie片段对我们代码请求影响不大，因为服务器往往会校验自己生成的cookie片段，对于浏览器自动生成的cookie片段不会校验。

在requests模块中发送带cookies字段的请求也是比较容易的操作，要实现这个，只需简单地传递一个**字典**给**cookies关键字**即可：

```
cookies = {'key1': 'value1',  'key2': 'value2'}
response = requests.get("url",  cookies=cookies)
```

3、3 verify关键字参数

数字证书（俗称ca证书，以下简称ca证书）为实现双方安全通信提供了电子认证。在因特网、公司内部网或外部网中，使用数字证书实现身份识别和电子信息加密。数字证书中含有密钥对（公钥和私钥）所有者的识别信息，通过验证识别信息的真伪实现对证书持有者身份的认证。

目前各大网站基本有自己的ca证书，但是不排除有的网站为了节约网站建设开销并没有购买ca证书。又因为requests模块在发送网络请求的时候，默认会验证ca证书。如果当前网站没有ca证书，那么就会报出如下的错误：

```
Traceback (most recent call last):
  File "C:/Users/admin/Desktop/学员问题/9306-01-00000000-山禾01(1).py", line 31, in <module>
    response = requests.get(url=url)
  File "C:\Anaconda3\lib\site-packages\requests\api.py", line 76, in get
    return request('get', url, params=params, **kwargs)
  File "C:\Anaconda3\lib\site-packages\requests\api.py", line 61, in request
    return session.request(method=method, url=url, **kwargs)
  File "C:\Anaconda3\lib\site-packages\requests\sessions.py", line 530, in request
    resp = self.send(prep, **send_kwargs)
  File "C:\Anaconda3\lib\site-packages\requests\sessions.py", line 643, in send
    r = adapter.send(request, **kwargs)
  File "C:\Anaconda3\lib\site-packages\requests\adapters.py", line 514, in send
    raise SSLError(e, request=request)
requests.exceptions.SSLError: HTTPSConnectionPool(host='data.stats.gov.cn', port=443): Max retries exceeded with url: / (Caused by
 SSLError(SSLError("bad handshake: Error([('SSL routines', 'tls_process_server_certificate', 'certificate verify failed')],)",),))
```

如果出现上述错误，那么我们可以用**verify**关键字参数，在请求的时候不验证网站的ca证书

```
response = requests.get("url", verify=False)
```

如果加了verify=False这个关键字参数，使用requests模块发送请求的时候会给你弹出一个警告，警告你当前的请求可能不安全，如下图所示：

这个警告对于后面的代码逻辑没有影响，有强迫症的可以考虑加入以下代码忽略警告：

```
import urllib3
urllib3.disable_warnings()
```

3、4 timeout关键字参数

如果对于requests模块发送的网络请求，请求数据的速度太慢，达不到你的要求。那么你可以考虑加上**timeout**关键字参数对于请求数据的时间做出限制，如下所示：

```
response = requests.get("url", timeout=限制时间)
```

> 限制时间单位以秒为单位，超过这个时间限制，程序报错。对于报错可以用异常捕获解决。

3、5 allow_redirects关键字参数

对于一些重定向的网络请求，比如登陆成功后跳转到用户个人页面。如果对于当前请求你不想要重定向，就需要当前地址数据，那么可以添加allow_redirects=False关键字，阻止当前请求的重定向。如下所示：

```
response = requests.get(url, allow_redirects=False)
```

3、6 proxies关键字参数

我们在做爬虫的过程中经常会遇到这样的情况：最初爬虫正常运行，正常抓取数据，然而一杯茶的功夫可能就会出现错误，比如403 Forbidden；这时候网页上可能会出现 “您的IP访问频率太高”这样的提示，过很久之后才可能解封，但是一会后又出现这种情况。

造成这种现象的原因是该网站已采取了一些防爬虫措施。 例如，服务器将在一个时间单位内检测IP请求的数量。 如果超过某个阈值，服务器将直接拒绝该服务并返回一些错误信息。 这种情况可以称为封IP，因此该网站成功禁止了我们的抓取工具。

想象一下，由于服务器检测到IP单位时间内的请求数量，因此我们使用某种方式来伪装IP，以使服务器无法识别由本地计算机发起的请求，因此我们可以成功地阻止IP被封。

对应的在使用requests模块发送网络请求时，可以用proxies关键字参数对本地计算机进行伪装，如下所示：

```
response = requests.get("url", proxies=代理)
```

requests模块官方文档

以下是requests模块中文文档和在GitHub上面的地址：

> 中文文档：https://requests.readthedocs.io/projects/cn/zh_CN/latest/
> github地址：https://github.com/requests/requests